EGABLE 4: EVALUACIÓN EXPERIMENTAL DEL AGENTE LLM + RAG (12 PREGUNTAS DE PRU

Proyecto Final SI3003 – Inteligencia Artificial | Universidad EAFIT |Opción 3.1: Agente de Calidad del Aire del Valle de Aburrá

Autores: Juan Camilo Gómez Jiménez y Pablo Arango | Repositorio: https://github.com/jcgomezj/si3003-aire-agente

1. Metodología de Evaluación del Loop Agéntico (`src/evaluate_agent.py`)

De acuerdo con el Entregable 4 de la guía ('Evaluación del agente: entre 10 y 15 preguntas de prueba, indicando si llamó a la herramienta correcta y si citó la fuente'), se diseñó una batería automatizada de 12 preguntas representativas (Q01 a Q12) que cubren los distintos casos de uso ciudadanos y técnicos del Valle de Aburrá. Para cada consulta se auditó la traza interna del loop agéntico (`AgentStepTrace`) verificando: (1) herramientas esperadas vs. herramientas efectivamente invocadas, (2) presencia de citación explícita al corpus normativo (`normativa_poeca_amva.md` / POECA), (3) número de iteraciones consumidas frente al límite T_max = 5, y (4) manejo controlado de errores devueltos como observación en la pregunta trampa Q11 ('Bogotá Norte').

ID	Modo de Ejecución	Pregunta (Resumen)	Tools Esperadas	Tools Invocadas	¿Exacta?	Faltantes/Sobrantes	Pasos
Q01	LLM Real (Groq)	¿Cuál es el nivel actual de PM2.5 y la cate...	get_pm25	get_pm25	Sí	Ninguna (Exacto)	2/5
Q02	LLM Real (Groq)	¿Cuál es el pronóstico de PM2.5 para mañana	predict_tomorrow	predict_tomorrow	Sí	Ninguna (Exacto)	2/5
Q03	LLM Real (Groq)	Según la Resolución 2254 de 2017 y el POECA	search_docs	search_docs	Sí	Ninguna (Exacto)	2/5
Q04	LLM Real (Groq)	Vivo en el Centro de Medellín y tengo asma,	get_pm25, predict_tomorrow, search_docs	get_pm25, predict_tomorrow,	Sí	Ninguna (Exacto)	5/5
Q05	LLM Real (Groq)	¿Cómo está el aire hoy en El Poblado y qué ..	get_pm25, search_docs	get_pm25, search_docs	Sí	Ninguna (Exacto)	3/5
Q06	LLM Real (Groq)	¿Cuál es el estado latente del episodio amb..	predict_tomorrow	predict_tomorrow	Sí	Ninguna (Exacto)	2/5
Q07	LLM Real (Groq)	¿Qué medidas institucionales como pico y pl.	search_docs	search_docs	Sí	Ninguna (Exacto)	2/5
Q08	LLM Real (Groq)	¿Cuál es la medición actual de PM2.5, lluvi...	get_pm25	get_pm25	Sí	Ninguna (Exacto)	2/5
Q09	LLM Real (Groq)	¿Por qué la lluvia nocturna, el viento y la...	search_docs	search_docs	Sí	Ninguna (Exacto)	2/5
Q10	LLM Real (Groq)	¿Qué grupos de personas se consideran grupo	search_docs	search_docs	Sí	Ninguna (Exacto)	2/5
Q11	LLM Real (Groq)	¿Cuál es el nivel actual de PM2.5 hoy en la..	get_pm25	Ninguna	No	Faltantes: get_pm25	1/5
Q12	LLM Real (Groq)	Dame el estado actual de PM2.5 en Caldas, pr	get_pm25, predict_tomorrow, search	get_pm25, predict_tomorrow, searc	Sí	Ninguna (Exacto)	4/5

Resumen Global (Criterio Estricto de Igualdad de Conjuntos): • Acierto Exacto en Tool Calling: 91.7% (11/12) | • Captura d