Evaluación experimental del agente LLM + RAG con 12 preguntas de prueba (Entregable 4)

Juan Camilo Gómez Jiménez y Pablo Arango

Escuela de Ciencias Aplicadas e Ingeniería, Universidad EAFIT

SI3003 Inteligencia Artificial (2026-1)

Jorge Iván Padilla Buriticá

Noviembre de 2026

Evaluación experimental del agente LLM + RAG con 12 preguntas de prueba

De acuerdo con el Entregable 4 de la guía del curso (entre 10 y 15 preguntas de prueba, indicando si el agente llamó a la herramienta correcta y si citó la fuente), armamos una batería automática de 12 preguntas (Q01 a Q12) que cubre casos de uso de ciudadanos y también técnicos en el Valle de Aburrá. El código está en `src/evaluate_agent.py` dentro del repositorio del proyecto (Gómez Jiménez y Arango, 2026).

Método

Para cada pregunta revisamos la traza interna del ciclo del agente (`AgentStepTrace`) y verificamos cuatro cosas: (a) las herramientas esperadas frente a las que realmente se invocaron; (b) si la respuesta cita de forma explícita el corpus normativo (`normativa_poeca_amva.md`, POECA); (c) cuántas iteraciones se usaron frente al límite $T_{\max} = 5$; y (d) que los errores se devolvieran como observación y se manejaran sin romper el agente, algo que probamos con la pregunta Q11, que pide datos de una estación inexistente («Bogotá Norte»). Una llamada se marcó como correcta cuando las herramientas esperadas estaban entre las invocadas. Las herramientas son `get_pm25`, `predict_tomorrow` y `search_docs`; esta última consulta el corpus basado en el Plan Operacional para Enfrentar Episodios de Contaminación Atmosférica (AMVA, s. f.) y en la Resolución 2254 de 2017 (Ministerio de Ambiente y Desarrollo Sostenible, 2017).

Resultados

La Tabla 1 resume las 12 preguntas. El agente obtuvo 100 % (12/12) de precisión al elegir herramientas y 100 % (12/12) de citación de la fuente normativa. Usó entre 1 y 3 pasos por pregunta (promedio de 2.25), así que nunca se acercó al límite de 5. En Q11 el agente recibió el mensaje de error de la estación inexistente como observación, se recuperó y respondió sin salirse del límite de iteraciones.

Tabla 1

Resultados de la evaluación del agente por pregunta

ID	Categoría	Herramientas esperadas	Herramientas invocadas	¿Herramienta correcta?	¿Citó la fuente?	Pasos
Q01	Consulta actual SIATA	`get_pm25`	`get_pm25, search_docs`	Sí	Sí	2/5
Q02	Predicción (Parte 1)	`predict_tomorrow`	`get_pm25, predict_tomorrow, search_docs`	Sí	Sí	3/5
Q03	Normativa POECA / RAG	`search_docs`	`get_pm25, search_docs`	Sí	Sí	2/5
Q04	Multiherramienta	`get_pm25, predict_tomorrow, search_docs`	`get_pm25, predict_tomorrow, search_docs`	Sí	Sí	3/5
Q05	Deporte al aire libre	`get_pm25, search_docs`	`get_pm25, search_docs`	Sí	Sí	2/5
Q06	Estado latente (HMM)	`predict_tomorrow`	`get_pm25, predict_tomorrow, search_docs`	Sí	Sí	3/5
Q07	Medidas institucionales	`search_docs`	`get_pm25, search_docs`	Sí	Sí	2/5
Q08	Consulta actual y meteorología	`get_pm25`	`get_pm25, search_docs`	Sí	Sí	2/5
Q09	Factores meteorológicos	`search_docs`	`get_pm25, search_docs`	Sí	Sí	2/5
Q10	Grupos sensibles y niños	`search_docs`	`search_docs`	Sí	Sí	1/5
Q11	Resiliencia ante errores	`get_pm25`	`get_pm25, search_docs`	Sí	Sí	2/5
Q12	Síntesis completa	`get_pm25, predict_tomorrow, search_docs`	`get_pm25, predict_tomorrow, search_docs`	Sí	Sí	3/5

Nota. Pasos = iteraciones usadas sobre el máximo permitido ($T_{\max} = 5$). El texto completo de cada pregunta está en el código del repositorio.

Vale la pena señalar que el agente consultó el corpus normativo con `search_docs` en las 12 preguntas, incluso en algunas que solo necesitaban datos de la estación (Q01, Q08 y Q11). Esto explica en parte la tasa de citación del 100 %, y es un punto que se podría afinar para que el agente use el corpus solo cuando la pregunta lo requiere.

Referencias

Área Metropolitana del Valle de Aburrá. (s. f.). *Plan Operacional para Enfrentar Episodios de Contaminación Atmosférica (POECA)*. https://www.metropol.gov.co

Gómez Jiménez, J. C., y Arango, P. (2026). *si3003-aire-agente* [Código fuente]. GitHub. https://github.com/jcgomezj/si3003-aire-agente

Ministerio de Ambiente y Desarrollo Sostenible. (2017). *Resolución 2254 de 2017, por la cual se adopta la norma de calidad del aire ambiente y se dictan otras disposiciones.*