EGABLE 4: EVALUACIÓN EXPERIMENTAL DEL AGENTE LLM + RAG (12 PREGUNTAS DE PRU

Proyecto Final SI3003 – Inteligencia Artificial | Universidad EAFIT |Opción 3.1: Agente de Calidad del Aire del Valle de Aburrá

Autores: Juan Camilo Gómez Jiménez y Pablo Arango | Repositorio: https://github.com/jcgomezj/si3003-aire-agente

1. Metodología de Evaluación del Loop Agéntico (`src/evaluate_agent.py`)

De acuerdo con el Entregable 4 de la guía ('Evaluación del agente: entre 10 y 15 preguntas de prueba, indicando si llamó a la herramienta correcta y si citó la fuente'), se diseñó una batería automatizada de 12 preguntas representativas (Q01 a Q12) que cubren los distintos casos de uso ciudadanos y técnicos del Valle de Aburrá. Para cada consulta se auditó la traza interna del loop agéntico (`AgentStepTrace`) verificando: (1) herramientas esperadas vs. herramientas efectivamente invocadas, (2) presencia de citación explícita al corpus normativo (`normativa_poeca_amva.md` / POECA), (3) número de iteraciones consumidas frente al límite T_max = 5, y (4) manejo controlado de errores devueltos como observación en la pregunta trampa Q11 ('Bogotá Norte').

ID	Categoría	Pregunta de Prueba (Resumen)	Tools Esperadas	Tools Invocadas	¿Tool OK?	¿Citó RAG?	Pasos
Q01	Consulta actual SIATA	¿Cuál es el nivel actual de PM2.5 y la categoría del aire	get_pm25	get_pm25, search_docs	Sí	Sí	2/5
Q02	Predicción Parte 1	¿Cuál es el pronóstico de PM2.5 para mañana en Itagüí se	predict_tomorrow, get_pm25	get_pm25, predict_tomorrow, sear	Sí	Sí	3/5
Q03	Normativa POECA / RAG	Según la Resolución 2254 de 2017 y el POECA, ¿qué signi	search_docs	get_pm25, search_docs	Sí	Sí	2/5
Q04	Multiherramienta (Actual	Vivo en el Centro de Medellín y tengo asma. ¿Cómo está	get_pm25, predict_tomorrow,	get_pm25, predict_tomorrow, sear	Sí	Sí	3/5
Q05	Deporte al aire libre	¿Cómo está el aire hoy en El Poblado y qué recomienda la	get_pm25, search_docs	get_pm25, search_docs	Sí	Sí	2/5
Q06	Estado Latente HMM (Parte	¿Cuál es el estado latente del episodio ambiental (HMM)	predict_tomorrow, get_pm25	get_pm25, predict_tomorrow, sear	Sí	Sí	3/5
Q07	Medidas Institucionales	¿Qué medidas institucionales como pico y placa ambienta	search_docs	get_pm25, search_docs	Sí	Sí	2/5
Q08	Consulta actual + Meteo	¿Cuál es la medición actual de PM2.5, lluvia y viento en	get_pm25	get_pm25, search_docs	Sí	Sí	2/5
Q09	Factores meteorológicos	¿Por qué la lluvia nocturna, el viento y la inversión térm	search_docs	get_pm25, search_docs	Sí	Sí	2/5
Q10	Grupos Sensibles / QNéng	¿Qué grupos de personas se consideran grupos sensibles s	search_docs	search_docs	Sí	Sí	1/5
Q11	Resiliencia / Manejo de	¿Cuál es el nivel actual de PM2.5 hoy en la estación de B	get_pm25	get_pm25, search_docs	Sí	Sí	2/5
Q12	Síntesis Completa (Sumo	Dame el estado actual de PM2.5 en Caldas, el pronóstico	get_pm25, predict_tomorrow,	get_pm25, predict_tomorrow, sear	Sí	Sí	3/5

Resumen Global de Métricas del Agente: • Precisión en Tool Calling: 100% (12/12) | • Tasa de Citación RAG: 100% (12/12